Lab08_Blumtritt

```
import polars as pl

df_basics = pl.read_csv("title.basics0.tsv.gz", separator="\t", null_values=r"\N")
df_ratings = pl.read_csv("title.ratings.tsv.gz", separator="\t", null_values=r"\N")
df_principals = pl.read_csv("title.principals0.tsv.gz", separator="\t", null_values=r"\N")

# Apenas registros do tipo filme ('movie')
df_movies = df_basics.filter(pl.col("titleType") == "movie")
```

1. Quais são os 5 filmes com as maiores notas (averageRating)? Apresente uma solução capaz de desempatar os filmes baseando-se no número de votos recebidos.

```
res_q1 = (
    df_movies
    .join(df_ratings, on = "tconst", how = "inner")
    .sort(["averageRating", "numVotes"], descending = [True, True])
    .select(["primaryTitle", "averageRating", "numVotes"])
    .head(5)
)

print("Top 5 filmes com maiores notas:")
```

```
Top 5 filmes com maiores notas:
```

```
print(res_q1)
```

```
shape: (5, 3)

 primaryTitle              averageRating   numVotes
 ---                       ---             ---
```

```
str                         f64             i64

Kaveri                      10.0            1023
Kurukku                     10.0            451
Jedal Dar Omghe 30 Metri    10.0            142
Sargashte                   10.0            134
Gorgeous Rascal             10.0            115
```

2. Qual é o gênero mais frequente entre os filmes com nota maior que 8?

```
res_q2 = (
    df_movies
    .join(df_ratings, on = "tconst", how = "inner")
    .filter(pl.col("averageRating") > 8)
    .filter(pl.col("genres").is_not_null())
    .with_columns(pl.col("genres").str.split(","))
    .explode("genres")
    .group_by("genres")
    .len()
    .sort("len", descending=True)
    .head(1)
)

print("Gênero mais frequente em filmes com nota > 8:")
```

```
Gênero mais frequente em filmes com nota > 8:
```

```
print(res_q2)
```

```
shape: (1, 2)

 genres       len
 ---          ---
 str          u32

 Documentary  10564
```

3. Quais são os 3 atores/atrizes que mais participaram de filmes com nota maior que 7.5?

```
res_q3 = (
    df_movies
    .join(df_ratings, on = "tconst", how = "inner")
    .filter(pl.col("averageRating") > 7.5)
    .join(df_principals, on = "tconst", how = "inner")
    .filter(pl.col("category").is_in(["actor", "actress"]))
    .group_by("nconst")
    .len()
    .sort("len", descending = True)
    .head(3)
)

print("Top 3 atores/atrizes com mais participações em filmes com nota > 7.5:")
```

```
Top 3 atores/atrizes com mais participações em filmes com nota > 7.5:
```

```
print(res_q3)
```

```
shape: (3, 2)

 nconst      len
 ---         ---
 str         u32

 nm0004660   231
 nm0595934   155
 nm3183374   124
```

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-10-14 18:25:12 -03"
```